

Home Work 2: balls and bins

Maksymilian Neumann

December 7, 2022

1 Wprowadzenie

Przeprowadziłem symulacje jednej z klasycznych modeli kul i urn dla ilości urn $n \in \{1000, 2000, \dots, 10000\}$ zbierając dane:

1. B_n = moment pierwszej kolizji
2. U_n = liczba pustych urn po wrzuceniu n kul
3. L_n = maksymalna liczba kul w urnie po wrzuceniu n kul
4. C_n = minimalna liczba rzutów, po której w każdej z urn jest co najmniej jedna kula
5. D_n = minimalna liczba rzutów, po której w każdej z urn są co najmniej dwie kule
6. $D_n - C_n$ = liczba rzutów od momentu C_n do momentu D_n

po 50 iteracji każdego n

2 Wyniki Zebranych Danych




Figure 1: B_n

Zależność między n a val średnim wydaje się być w tym przypadku logarytmiczna. Natomiast koncentracja wyników wokół średniej jest coraz słabsza im n jest większe.




Figure 2: U_n

Można zwrócić uwagę na silną zależność liniową między n a średnim val . Koncentracja wyników wokół średniej jest mocna oraz w miarę stała.,




Figure 3: L_n

Zależność między n a val średnim wydaje się być w tym przypadku logarytmiczna. Poziom koncentracji wyników w okół średniej wydaje się być w miarę stały.




Figure 4: C_n

Widać zależność liniową między n i średnim val . Podobnie jak przy statystyce B_n podczas zwiększania n wyniki oddalają się bardziej od średniej.




Figure 5: D_n

Widoczna jest silna liniowa zależność. Im większe n tym większe rozrzucenie wyników w okół średniej.




Figure 6: $D_n - C_n$

Widoczna jest silna liniowa zależność. Im większe n tym większe rozrzucenie wyników w okół średniej. a

3 Wykresy dodatkowe

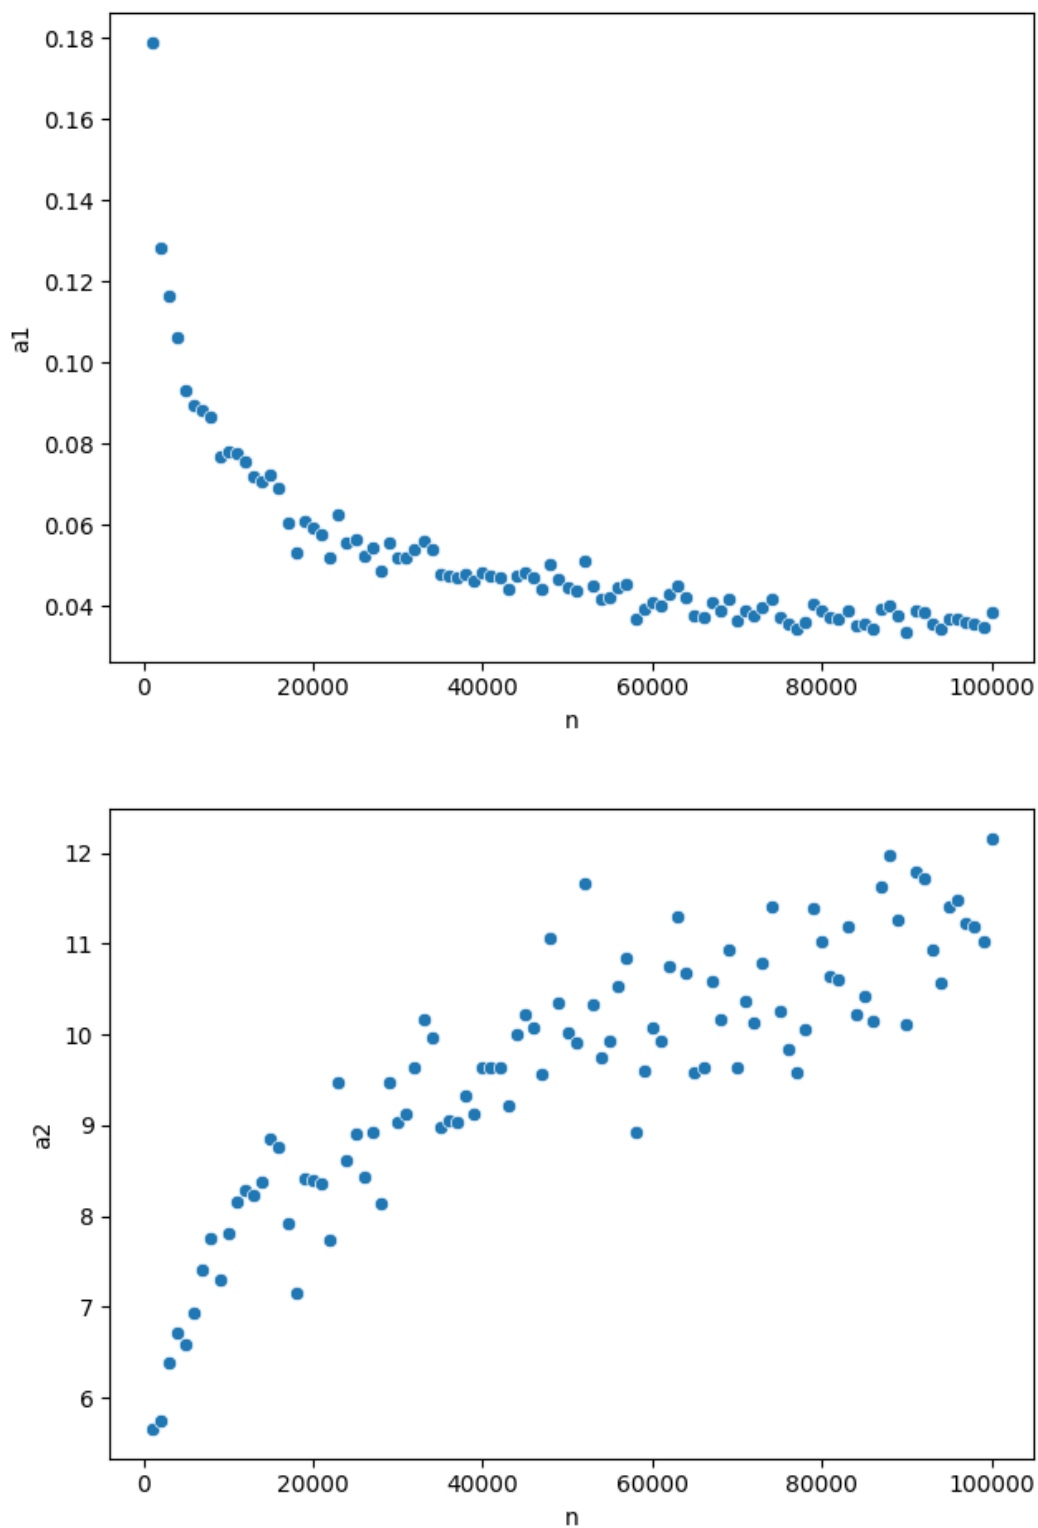


Figure 7: $\frac{b(n)}{n}$ i $\frac{b(n)}{\sqrt{n}}$




Figure 8: $\frac{u(n)}{n}$





Figure 9: $\frac{l(n)}{\ln(n)}$ i $\frac{l(n)}{(\ln(n)/\ln(\ln(n))}$




Figure 10: $\frac{l(n)}{\ln(\ln(n))}$

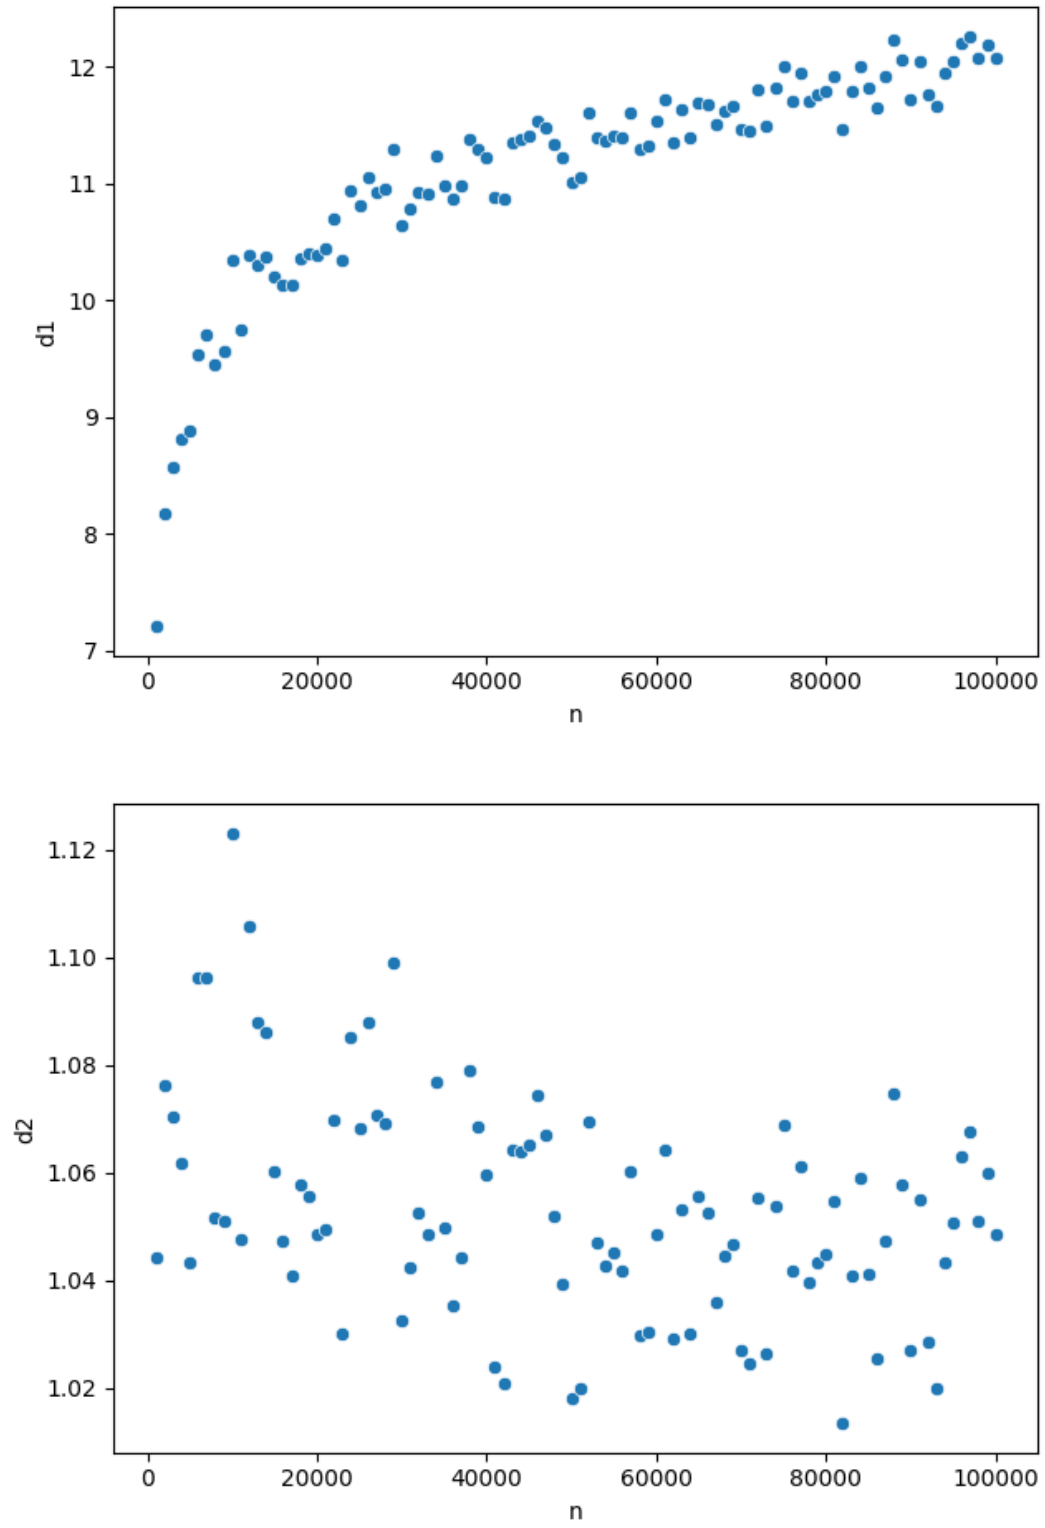


Figure 11: $\frac{c(n)}{n}$ i $\frac{c(n)}{n \cdot \ln(n)}$




Figure 12: $\frac{c(n)}{n^2}$

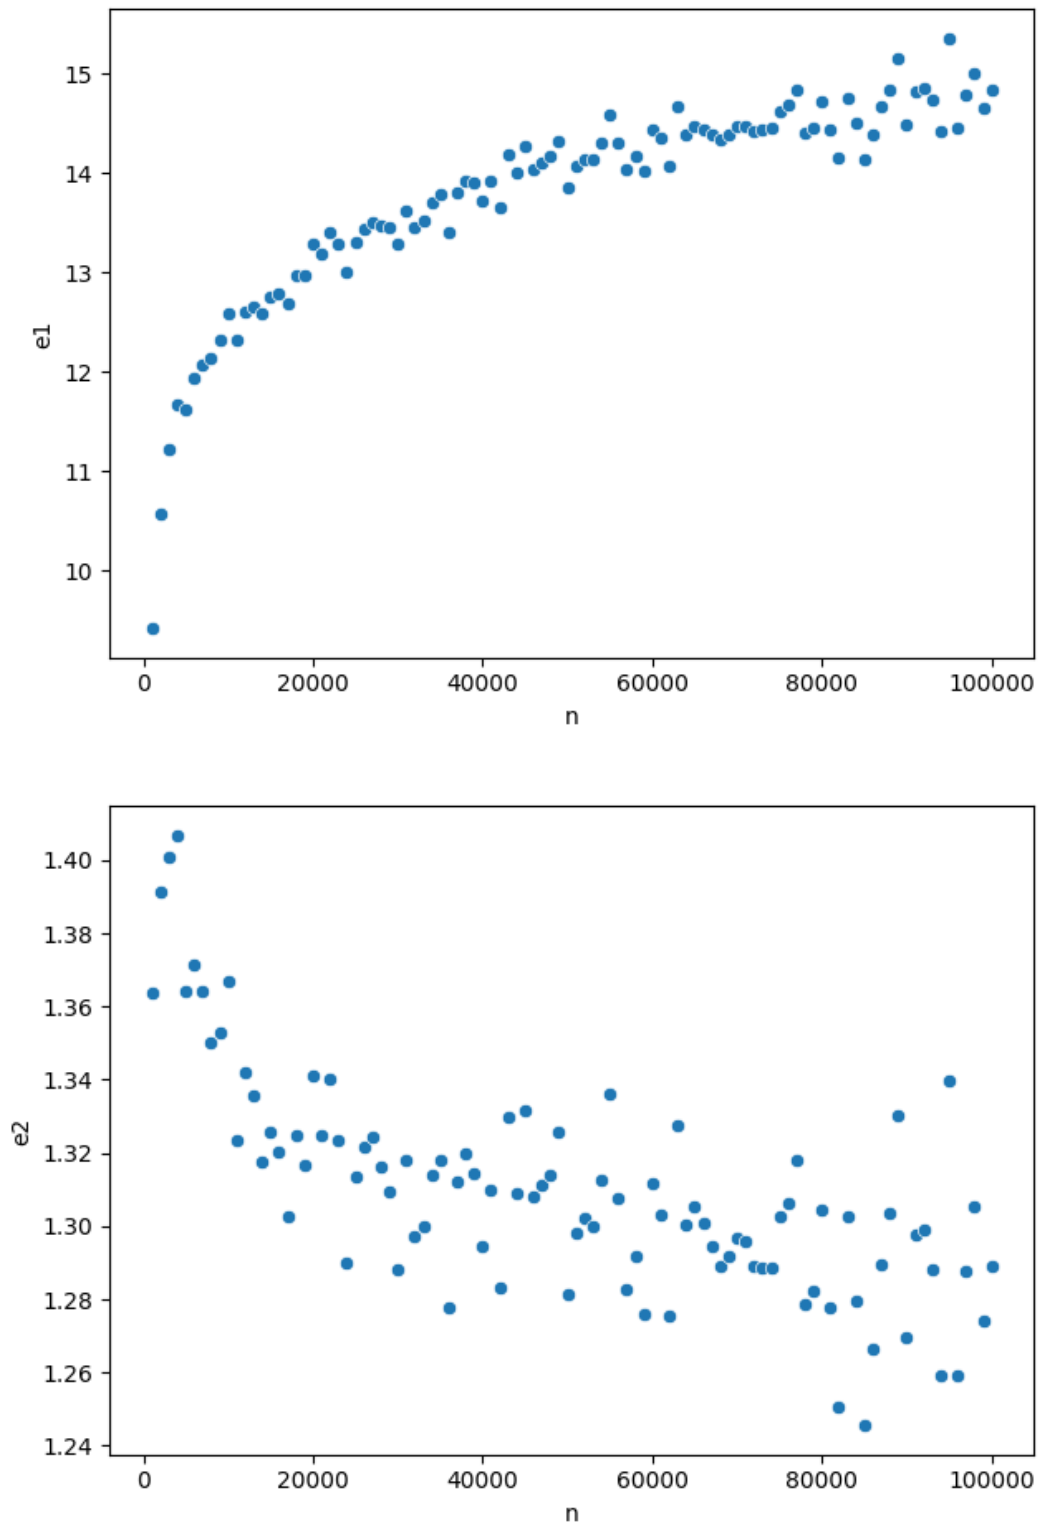


Figure 13: $\frac{d(n)}{n}$ i $\frac{d(n)}{n \cdot \ln(n)}$




Figure 14: $\frac{c(n)}{n^2}$

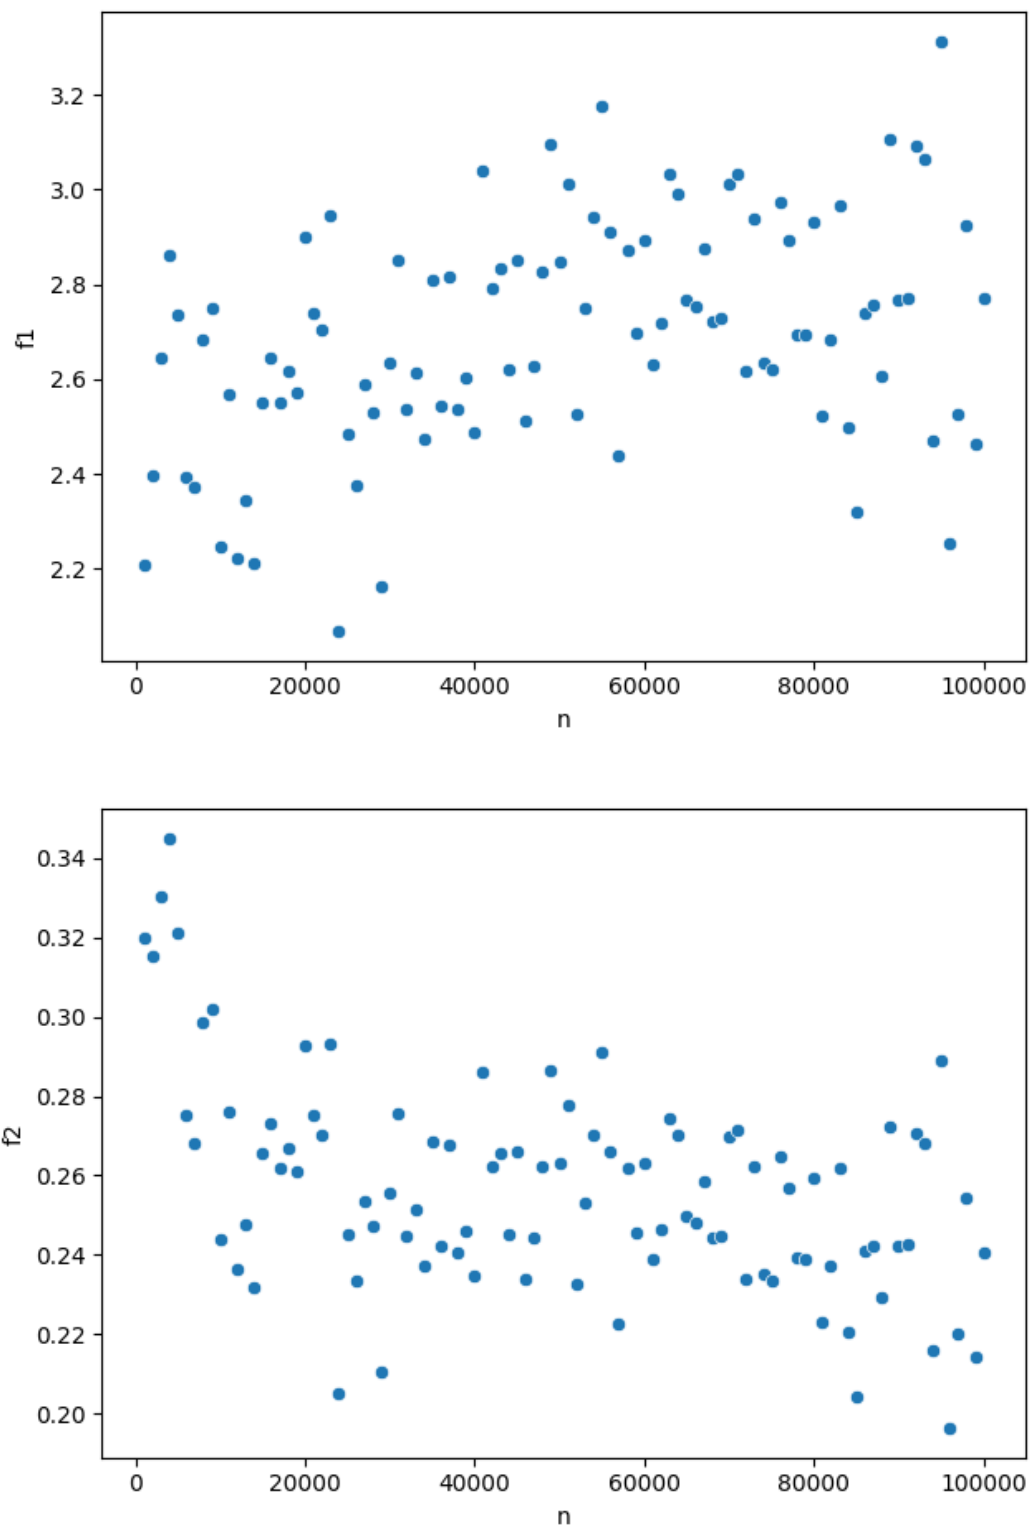


Figure 15: $\frac{d(n)-c(n)}{n}$ i $\frac{d(n)-c(n)}{n \cdot \ln(n)}$




Figure 16: $\frac{d(n)-c(n)}{n \cdot \ln(\ln(n))}$

4 Wnioski i Odpowiedzi

Statystyka B_n jest analogiczna do "birthday paradox" wystarczy pomyśleć tylko o urnach jako dniach w roku a kulach do nich wrzucanych jak osobach które się rodzą danego dnia. Pierwsze zdeże nie będzie tu analogiczne do dwóch osób o tym samym dniu urodzin.

Statystyka C_n jest analogiczna natomiast do "Coupon collector's problem" który polega na losowaniu n rodzajów kuponów każdy z równą szansą wylosowania i zebraniu wszystkich rodzajów kuponów. W naszym przykładzie urna będzie rodzajem kuponu a kula wrzucona do urny będzie oznaczać wylosowanie tego rodzaju kuponu więc kiedy w każdej urnie będziemy mieli co najmniej 1 kulę wylosujemy wszystkie rodzaje kuponów.

W kryptografii lekcje nauczone od "birthday paradox" wykorzystywane są jako atak kryptograficzny tak zwany "Birthday attack" który polega na znalezieniu kolizji w hashu. W porównaniu do "Preimage attack" które dla n bitowego hashu ma $O(2^n)$ "Birthday attack" ma $O(\sqrt{2^n})$ oraz jest szeroko przypuszczone że komputer kwantowy mógłby go wykonać z $O(\sqrt[3]{2^n})$